ANN_Titanic

December 5, 2017

1 Prevendo Sobrevivência do Titanic

Modelagem de uma rede neural para prever sobrevivência do Navio Titanic. Fonte dos dados: https://www.kaggle.com/c/titanic

Alunos:

- Davi P. Neto
- Giovane N. M. Costa
- Henrique A. Batochi

Referências:

https://www.kdnuggets.com/2016/10/beginners-guide-neural-networks-python-scikit-learn.html/2

https://www.kaggle.com/jeffd23/scikit-learn-ml-from-start-to-finish

http://scikit-learn.org/stable/modules/neural_networks_supervised.html

1.1 Dicionário de Dados

Variable: Definition Key

survival: Survival 0 = No, 1 = Yes

pclass: Ticket class 1 = 1st, 2 = 2nd, 3 = 3rd

sex: Sex (female or male)

Age: Age in years

sibsp: # of siblings / spouses aboard the Titanic

parch: # of parents / children aboard the Titanic

ticket: Ticket number

fare: Passenger fare

cabin: Cabin number

embarked: Port of Embarkation C = Cherbourg, Q = Queenstown, S = Southampton

Variable Notes

pclass: A proxy for socio-economic status (SES) 1st = Upper 2nd = Middle 3rd = Lower

age: Age is fractional if less than 1. If the age is estimated, is it in the form of xx.5

sibsp: The dataset defines family relations in this way...

Sibling = brother, sister, stepbrother, stepsister Spouse = husband, wife (mistresses and fiancés were ignored)

parch: Some children travelled only with a nanny, therefore parch=0 for them. Parent = mother, father Child = daughter, son, stepdaughter, stepson

1.2 Importando Bibliotecas

In [2]:
```
import numpy as np # Para trabalhar com vetores e fazer outras operações matemáticas
import pandas as pd # Pandas Dataframe: processamento de dados
import matplotlib.pyplot as plt # Matplot: gráficos
import seaborn as sns #Seaborn: simplica o processo de criar gráficos

# Abrir os graficos no navegador em vez de em outra janela
%matplotlib inline

#Sci-kit Learn: biblioteca de machine learning para python, da qual importamos rede ne
from sklearn.neural_network import MLPClassifier
```

1.3 Importando o Dataset

In [3]:
```
# Criamos um Pandas Dataframe a partir do csv.
# Dataframe é tipo uma Classe para tabelas com várias funções de manipulação
data = pd.read_csv('train.csv')
```

In [4]:
```
# Pegamos 10 amostras dos dados para dar uma olhada
data.sample(10)
```

Out[4]:

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
297	298	0	1	Allison, Miss. Helen Loraine	female	2.0	1	2	113781	151.5500	C22 C26	S
798	799	0	3	Ibrahim Shawah, Mr. Youseff	male	30.0	0	0	2685	7.2292	NaN	C
450	451	0	2	West, Mr. Edwy Arthur	male	36.0	1	2	C.A. 34651	27.7500	NaN	S
636	637	0	3	Leinonen, Mr. Antti Gustaf	male	32.0	0	0	STON/O 2. 3101292	7.9250	NaN	S
650	651	0	3	Mitkoff, Mr. Mito	male	NaN	0	0	349221	7.8958	NaN	S
665	666	0	2	Hickman, Mr. Lewis	male	32.0	2	0	S.O.C. 14879	73.5000	NaN	S
154	155	0	3	Olsen, Mr. Ole Martin	male	NaN	0	0	Fa 265302	7.3125	NaN	S
409	410	0	3	Lefebre, Miss. Ida	female	NaN	3	1	4133	25.4667	NaN	S
34	35	0	1	Meyer, Mr. Edgar Joseph	male	28.0	1	0	PC 17604	82.1708	NaN	C
353	354	0	3	Arnold-Franchi, Mr. Josef	male	25.0	1	0	349237	17.8000	NaN	S

In [5]:
```
# Estatística básica dos campos numericos do Dataframe
# Apenas 38% das pessoas sobreviveram
data.describe()
```

```
Out[5]:        PassengerId    Survived      Pclass         Age       SibSp  \
count   891.000000  891.000000  891.000000  714.000000  891.000000
mean    446.000000    0.383838    2.308642   29.699118    0.523008
std     257.353842    0.486592    0.836071   14.526497    1.102743
min       1.000000    0.000000    1.000000    0.420000    0.000000
25%     223.500000    0.000000    2.000000   20.125000    0.000000
50%     446.000000    0.000000    3.000000   28.000000    0.000000
75%     668.500000    1.000000    3.000000   38.000000    1.000000
max     891.000000    1.000000    3.000000   80.000000    8.000000

            Parch        Fare
count  891.000000  891.000000
mean     0.381594   32.204208
std      0.806057   49.693429
min      0.000000    0.000000
25%      0.000000    7.910400
50%      0.000000   14.454200
75%      0.000000   31.000000
max      6.000000  512.329200
```

1.4 Tratando os dados

1.4.1 Checando por dados ausentes

As variáveis Idade, Cabine e Local de Embarque precisam ser preenchidas

```
In [6]: data.apply(lambda x: sum(x.isnull()),axis=0)
```

```
Out[6]: PassengerId      0
        Survived         0
        Pclass           0
        Name             0
        Sex              0
        Age            177
        SibSp            0
        Parch            0
        Ticket           0
        Fare             0
        Cabin          687
        Embarked         2
        dtype: int64
```

1.4.2 Idade

Segundo o dataset, existem idades "quebradas (x.5) que foram estimadas, idades 1 (bebes) e idades ausentes. Para facilitar a análise, preenchemos as idades ausentes com a mediana e as separamos as idades por categorias:

Bebê (0 a 5), Criança (5 a 12), Adolescente (12 a 18), Jovem (18 a 25), Jovem Adulto (25 a 35), Adulto (35 a 60), Idoso (60 a 81)

```
In [7]: print data.Age.sort_values().unique()
        print data.Age.median()
```

```
[  0.42   0.67   0.75   0.83   0.92   1.     2.     3.     4.     5.     6.
   7.     8.     9.    10.    11.    12.    13.    14.    14.5   15.    16.
  17.    18.    19.    20.    20.5   21.    22.    23.    23.5   24.    24.5
  25.    26.    27.    28.    28.5   29.    30.    30.5   31.    32.    32.5
  33.    34.    34.5   35.    36.    36.5   37.    38.    39.    40.    40.5
  41.    42.    43.    44.    45.    45.5   46.    47.    48.    49.    50.
  51.    52.    53.    54.    55.    55.5   56.    57.    58.    59.    60.
  61.    62.    63.    64.    65.    66.    70.    70.5   71.    74.    80.
    nan]
28.0
```

```
In [8]: # Preenchemos as idades ausentes com valores negativos com a mediana
        data.Age = data.Age.fillna(28)

        # limites dos grupos
        bins = (0, 5, 12, 18, 25, 35, 60, 120)

        #nomes dos grupos
        grupos = ['Bebê'.decode('utf-8'), 'Criança'.decode('utf-8'), 'Adolescente',
                  'Jovem', 'Jovem Adulto', 'Adulto', 'Idoso']

        # Cada linha do dataframe tem um indice que a identifica.
        # Pd.cut faz a categorização atribuindo uma categoria para cada indice
        categorias = pd.cut(data.Age, bins, labels=grupos)

        # Atualizamos o campo idade do dataframe com o novo vetor criado
        data.Age = categorias
```

1.4.3 Cabine

Todas as cabines começam como uma letra, que vão de 'A' a 'G', e uma 'T' . Essa letra pode ser interessante, por isso a separamos dos números e jogamos eles fora. Além disso, também existem valores ausentes que preenchemos com a letra 'N'.

```
In [9]: # Preenchendo valores ausentes
        data.Cabin = data.Cabin.fillna('N')

        # Substituindo a Cabine pela primeira letra
        data.Cabin = data.Cabin.apply(lambda x: x[0])

        print data.Cabin.value_counts()
```

```
N    687
C     59
B     47
```

```
D     33
E     32
A     15
F     13
G      4
T      1
Name: Cabin, dtype: int64
```

1.4.4 Tarifa

Simplificamos também as tarifas dividindo em 4 grupos conforme quartis. (Um quartil é qualquer um dos três valores que divide o conjunto ordenado de dados em quatro partes iguais, e assim cada parte representa 1/4 da amostra ou população /Wikipedia)

```
In [10]: data.Fare.describe()
```

```
Out[10]: count    891.000000
         mean      32.204208
         std       49.693429
         min        0.000000
         25%        7.910400
         50%       14.454200
         75%       31.000000
         max      512.329200
         Name: Fare, dtype: float64
```

```
In [11]: # Preenchendo os valores ausentes
         data.Fare = data.Fare.fillna(-0.5)

         # Limites dos quartis conforme a função describe()
         bins = (-1, 0, 8, 15, 31, 513)

         # Nome dos grupos
         grupos = ['Desconhecido', '1_Quartil', '2_Quartil', '3_Quartil', '4_Quartil']

         # Divisão das categorias
         categorias = pd.cut(data.Fare, bins, labels=grupos)

         # Atualizando a coluna
         data.Fare = categorias
```

1.4.5 Nome

É razoável admitir que o nome de uma pessoa não interefere na probabilidade de sobrevivência dela. No entanto, o prefixo (Mr. Miss, etc..) pode dizer alguma coisa, pois está relacionado ao sexo e estado civíl.

```
In [12]: # Ex: Reeves, Mr. David

         # Pegando o prefixo
         data['NamePrefix'] = data.Name.apply(lambda x: x.split(' ')[1])
```

1.4.6 Familia

Vamos criar uma variavel familia somando a SibSp e Parch

```
In [13]: data['Family'] = data['SibSp'] + data['Parch']
```

1.4.7 Local de Embarque

A maioria embarcou em Southampton, então vamos preencher os valores com esse local

```
In [14]: # Preenchendo valores ausentes
         print data['Embarked'].value_counts()
         data.Embarked = data.Embarked.fillna('S')
```

```
S    644
C    168
Q     77
Name: Embarked, dtype: int64
```

1.4.8 Eliminando Features

Por fim, eliminamos as features irrelevantes para o aprendizado, como o número da passagem, o nome, e o local onde embarcou.

```
In [15]: data = data.drop(['PassengerId', 'Ticket', 'Name', 'SibSp', 'Parch'], axis=1)
         data.head()
```

```
Out[15]:    Survived  Pclass     Sex           Age       Fare Cabin Embarked  \
         0         0       3    male         Jovem  1_Quartil     N        S
         1         1       1  female        Adulto  4_Quartil     C        C
         2         1       3  female  Jovem Adulto  1_Quartil     N        S
         3         1       1  female  Jovem Adulto  4_Quartil     C        S
         4         0       3    male  Jovem Adulto  2_Quartil     N        S

           NamePrefix  Family
         0        Mr.       1
         1       Mrs.       1
         2      Miss.       0
         3       Mrs.       1
         4        Mr.       0
```

1.5 Análise Exploratória

Plotamos alguns gráficos para ver como nossas varíaveis se relacionam com a sobrevivência:

```
In [16]: sns.barplot(x="Embarked", y="Survived", data=data);
```

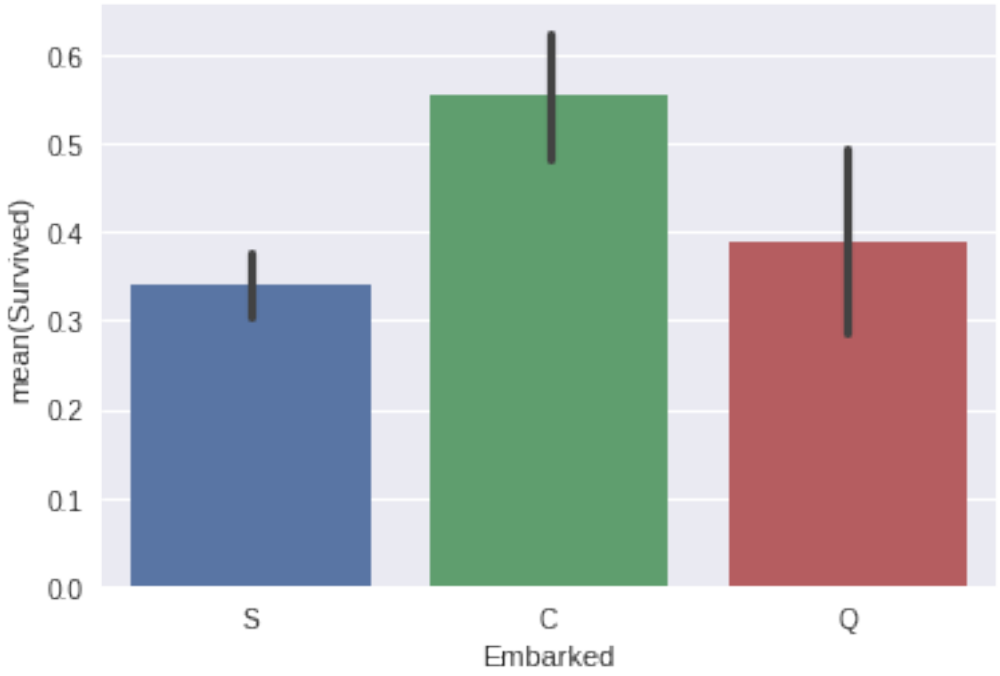


```
In [17]: sns.barplot(x="Family", y="Survived", data=data);
```

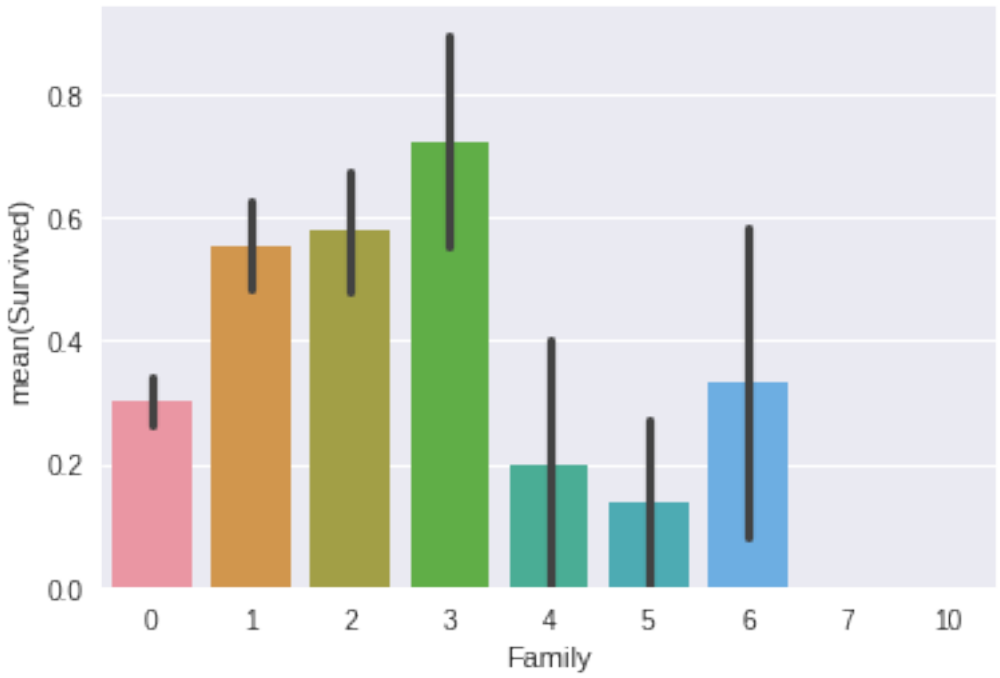

In [18]: sns.barplot(x="Pclass", y="Survived", data=data);

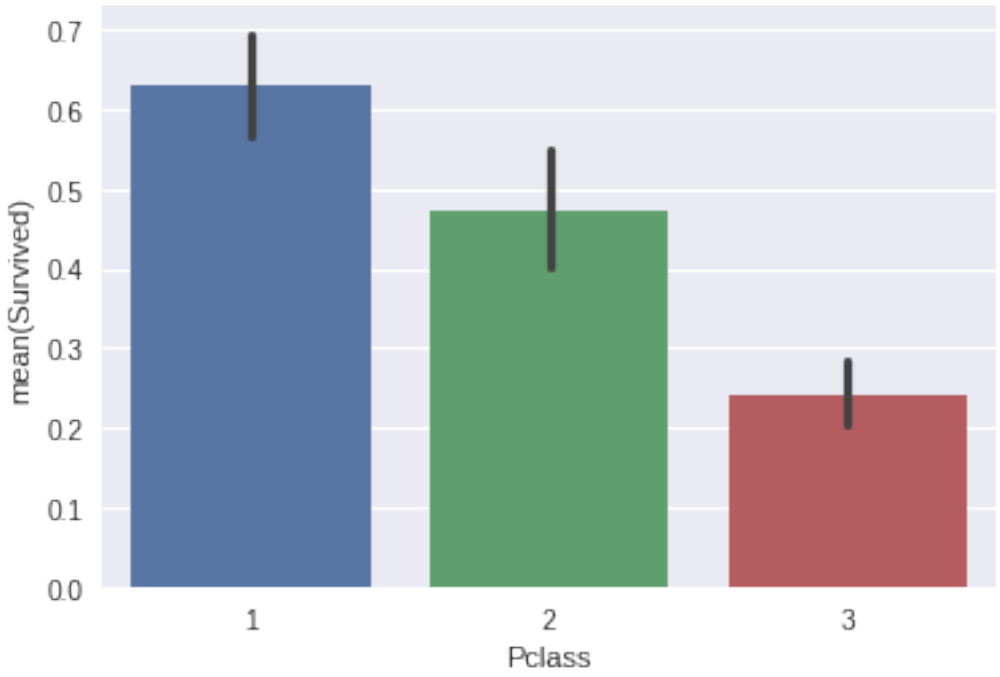

In [19]: sns.barplot(x="Sex", y="Survived", data=data);

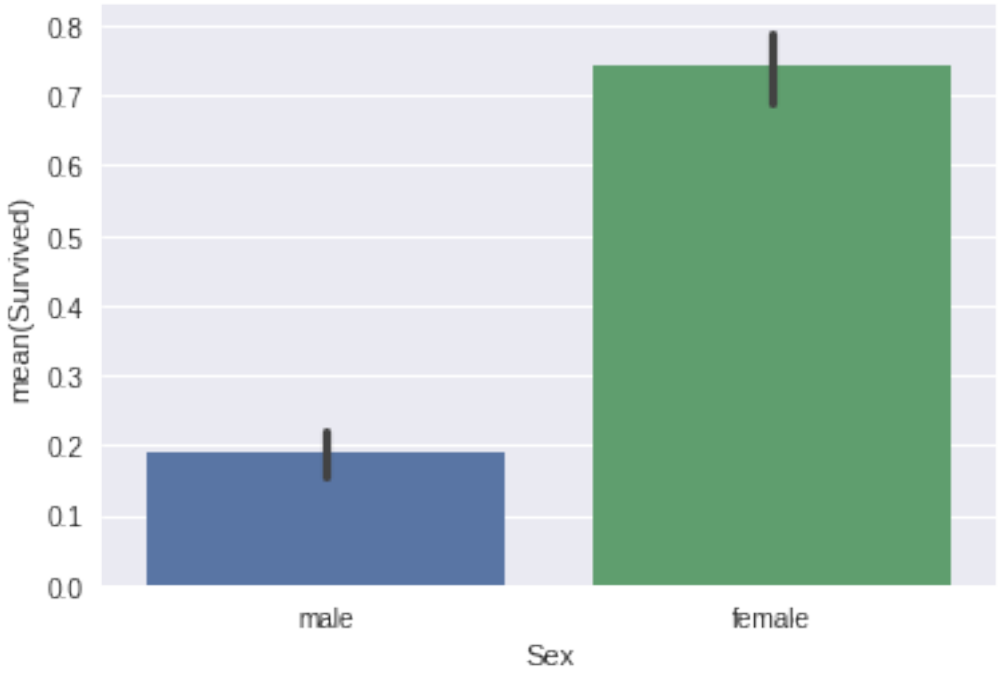

In [20]:
```
sns.barplot(x="Fare", y="Survived", data=data);
```

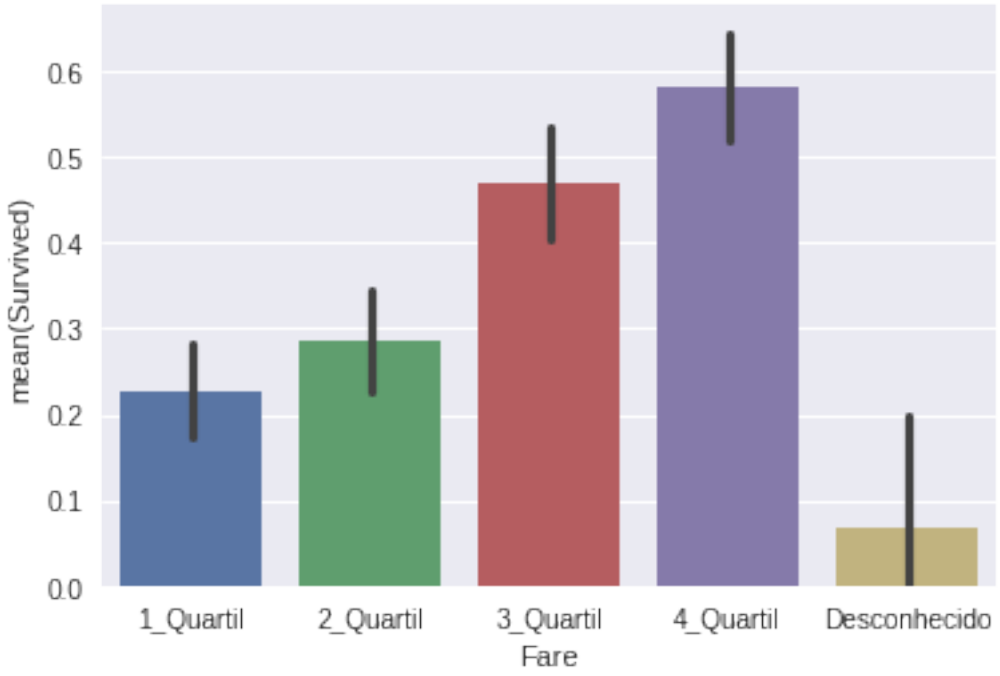

In [21]:
```
ordem = ['Bebê'.decode('utf-8'), 'Criança'.decode('utf-8'), 'Adolescente',
         'Jovem', 'Jovem Adulto', 'Adulto', 'Idoso']
plt.xticks(rotation=30)
sns.barplot(x="Age", y="Survived", order=ordem, data=data);
```

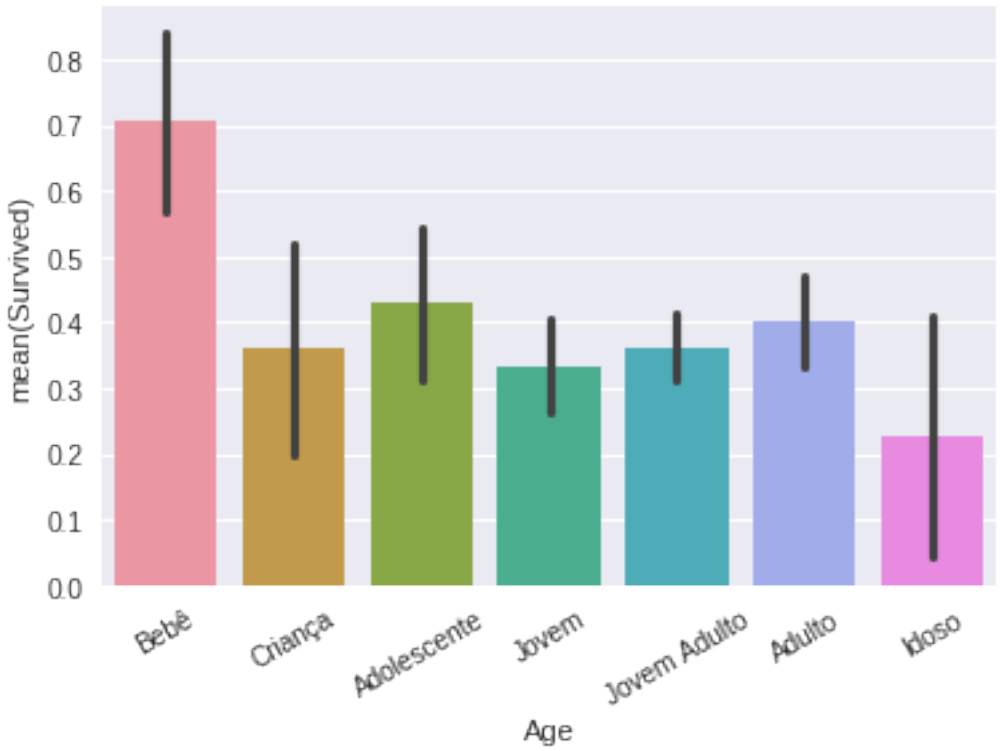


```
In [22]: sns.barplot(x="Cabin", y="Survived", data=data);
```

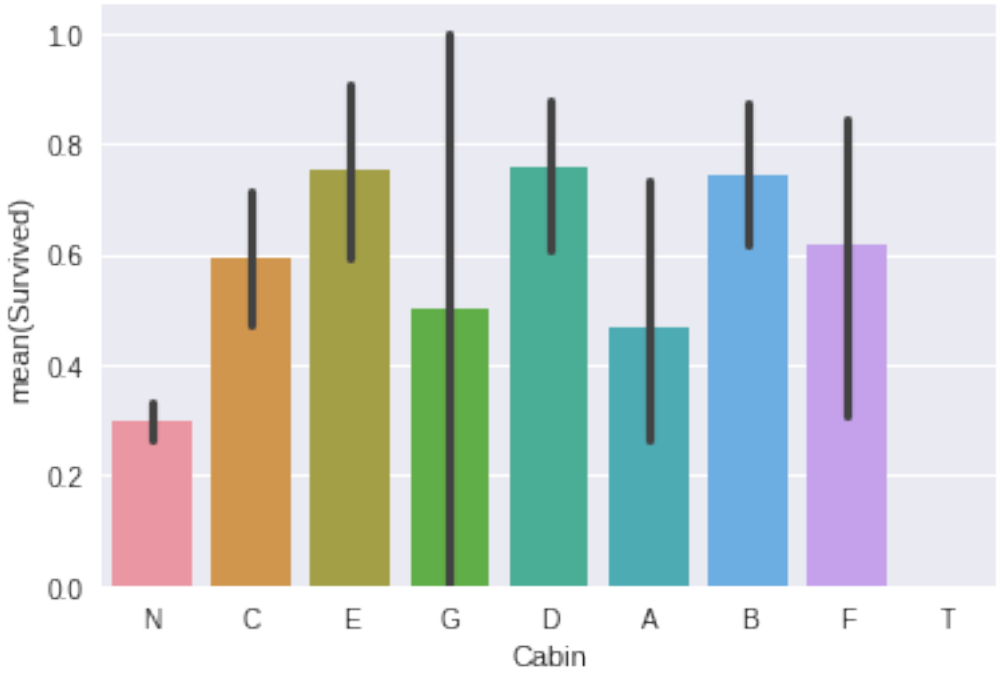

```
In [23]: plt.figure(figsize=(20,5))
         plt.xticks(rotation=45)
         sns.barplot(x="NamePrefix", y="Survived", data=data)
```

```
Out[23]: <matplotlib.axes._subplots.AxesSubplot at 0x7eff61c228d0>
```

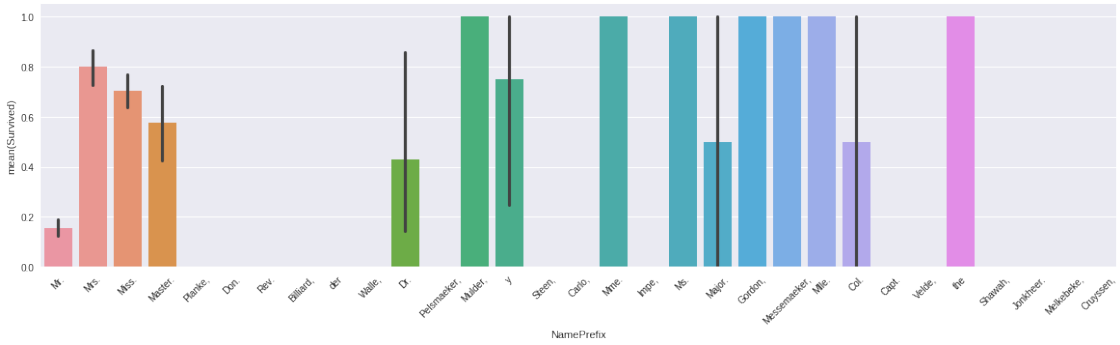

Como podemos ver, algumas características se destacam, como: - Familia: pessoas viajando sozinhas ou com mais de 3 familiares tem menos chance de sobreviver; - Sexo: mulheres tem mais chance de sobreviver; - Classe: quanto menor a classe, melhor a chance de sobreviver; - Tarifa: passageiros que pagaram mais tem mais chance de sobreviver; - Idade: idosos, jovens e crianças foram os que menos sobreviveram;
- Cabine: as cabines E, D e B foram as com mais sobreviventes;
- Embarque: pessoas que embarcaram em Cherbourg tem mais chances de sobreviver;

1.6 Transformando os Dados

Para utilizar em redes neurais, precisamos dos dados em números em vez de strings. Para issos, utilizamos a classe LabelEncoder do Scikit-learn que converte cada string diferente em um número diferente.

```
In [24]: from sklearn import preprocessing
         def encode_features(data):
             features = ['Fare', 'Age', 'Sex', 'Cabin', 'NamePrefix', 'Family', 'Embarked']

             for feature in features:
                 le = preprocessing.LabelEncoder()
                 le = le.fit(data[feature])
                 data[feature] = le.transform(data[feature])
             return data

         data = encode_features(data)
         data.head()
```

Out[24]:

	Survived	Pclass	Sex	Age	Fare	Cabin	Embarked	NamePrefix	Family
0	0	3	1	5	0	7	2	17	1
1	1	1	0	1	3	2	0	18	1
2	1	3	0	6	0	7	2	14	0
3	1	1	0	6	3	2	2	18	1
4	0	3	1	6	1	7	2	17	0

1.7 Dividindo o Dataset em Treino/Test

Precisamos ensinar e testar a rede. Assim, antes dividimos o dataset em quatro: - Primeiro, um dataframe somente com as features que utilizaremos para prever a sobrevivência; - Segundo, um dataframe somente com o valor que queremos prever (se a pessoa sobreviveu ou não); - Finalmente, para cada um desses, dividimos aleatóriamente 20% dos dados para teste e o resto para treino.

In [25]:
```
from sklearn.model_selection import train_test_split

# Cria um dataframe sem a informação sobre sobrevivência
X_all = data.drop(['Survived'], axis=1)

# Cria um array com o 'target' (se o individuo sobreviveu ou nao -- o que queremos pr
y_all = data['Survived']

# Porcentagem dos dados que serão utilizados para teste (20%)
num_test = 0.20

# Semente utilizada para gerar o numero aleatório e dividir o dataset
seed = 23

# Divide aleatoriamente os dados em subsets de treino e test
X_train, X_test, y_train, y_test = train_test_split(X_all, y_all, test_size=num_test,
```

In [26]:
```
print(X_train.shape)
print(X_test.shape)
```

```
(712, 8)
(179, 8)
```

1.8 Feature Scaling

Conforme a documentação, o Multi-layer Perceptron é sensível a 'escala' das variáveis. Ou seja, se uma variável possui variância que sua ordem de magnitude é maior que as outras, ela pode dominar a função objetivo. Assim, recomenda-se 'padronizar' os dados de forma a ter média 0 e variância 1. Para isso utilizamos a função StandardScaler.

In [27]:
```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
```

```
# Don't cheat - fit only on training data
scaler.fit(X_train)
X_train = scaler.transform(X_train)

# apply same transformation to test data
X_test = scaler.transform(X_test)
```

```
In [28]: X_train
```

```
Out[28]: array([[-1.55453842, -1.33463478,  0.45493896, ...,  0.5930441 ,
                  0.67645173,  0.04773979],
                [ 0.83861046,  0.74926865,  0.45493896, ...,  0.5930441 ,
                  0.3137758 , -0.5935947 ],
                [ 0.83861046,  0.74926865, -1.73664792, ...,  0.5930441 ,
                  0.3137758 ,  0.68907427],
                ...,
                [ 0.83861046, -1.33463478, -1.29833054, ...,  0.5930441 ,
                  0.67645173,  0.04773979],
                [-1.55453842, -1.33463478,  0.45493896, ..., -1.89076414,
                 -0.77425198,  1.97174324],
                [ 0.83861046,  0.74926865, -1.29833054, ...,  0.5930441 ,
                 -2.95030754,  0.68907427]])
```

1.9 Treinando a Rede

Primeiramente utilizamos o GridSearchCV para encontrar o melhor alpha e numero da neuronios para a rede neural (dentro de uma lista). Para essa rede, utilizamos taxa de aprendizado de 0.001, função de ativação tangente hiperbólica e backpropagation (mais especificamente, stochastic gradient descent). Depois treinamos a rede e a utilizamos para prever a sobrevivência. Essa parte demora cerca de 30s.

```
In [32]: from sklearn.model_selection import GridSearchCV
         from sklearn.metrics import make_scorer, accuracy_score

         # Choose the type of classifier.
         clf = MLPClassifier(max_iter=500, solver='sgd', activation='tanh',
                             learning_rate_init='0.001', random_state=1)

         # Choose some parameter combinations to try
         parameters = {'alpha': 10.0 ** -np.arange(1, 7),
                       'hidden_layer_sizes': [(9), (10,8), (20,20)]}

         # Type of scoring used to compare parameter combinations
         acc_scorer = make_scorer(accuracy_score)

         # Run the grid search
         grid_obj = GridSearchCV(clf, parameters, scoring=acc_scorer)
         grid_obj = grid_obj.fit(X_train, y_train)
```

```
# Set the clf to the best combination of parameters
clf = grid_obj.best_estimator_

# Fit the best algorithm to the data.
clf.fit(X_train, y_train)
```

```
Out[32]: MLPClassifier(activation='tanh', alpha=0.10000000000000001, batch_size='auto',
       beta_1=0.9, beta_2=0.999, early_stopping=False, epsilon=1e-08,
       hidden_layer_sizes=(10, 8), learning_rate='constant',
       learning_rate_init='0.001', max_iter=500, momentum=0.9,
       nesterovs_momentum=True, power_t=0.5, random_state=1, shuffle=True,
       solver='sgd', tol=0.0001, validation_fraction=0.1, verbose=False,
       warm_start=False)
```

1.10 Validando os Resultados com KFold

Utilizando K-Fold, com k = 10, a rede apresentou uma acurácia média de 0.75, que significa um bom resultado.

```
In [33]: predictions = clf.predict(X_test)

from sklearn.metrics import confusion_matrix
from sklearn.model_selection import KFold


def run_kfold(clf):

    kf = KFold(n_splits=7, shuffle=True)
    outcomes = []
    fold = 0
    for train_index, test_index in kf.split(data):
        fold += 1
        X_train2, X_test2 = X_all.values[train_index], X_all.values[test_index]
        y_train2, y_test2 = y_all.values[train_index], y_all.values[test_index]
        clf.fit(X_train2, y_train2)
        predictions = clf.predict(X_test2)
        accuracy = accuracy_score(y_test2, predictions)
        outcomes.append(accuracy)
        print("Fold {0} accuracy: {1}".format(fold, accuracy))
    mean_outcome = np.mean(outcomes)
    print("Mean Accuracy: {0}".format(mean_outcome))

run_kfold(clf)

mat = confusion_matrix(y_test,predictions)

f,ax = plt.subplots(figsize=(6, 6))
```

```
        plt.title('Confusion Matrix'.decode('utf-8'))
        sns.heatmap(mat, annot=True, linewidths=.5, fmt= 'd',ax=ax,
                    xticklabels=['Ac_Morte', 'Ac_Sobreviveu'], yticklabels=['Prd_Morte', 'Prd_
```

```
Fold 1 accuracy: 0.7578125
Fold 2 accuracy: 0.7578125
Fold 3 accuracy: 0.803149606299
Fold 4 accuracy: 0.732283464567
Fold 5 accuracy: 0.803149606299
Fold 6 accuracy: 0.755905511811
Fold 7 accuracy: 0.685039370079
Mean Accuracy: 0.756450365579
```

```
Out[33]: <matplotlib.axes._subplots.AxesSubplot at 0x7eff61d52bd0>
```